

1) 프로젝트 개요

- 목적: 연구자 1이 학습한 회귀 모델(`model.pkl`)을 연구자 2의 Jupyter 환경에서 재사용해 추론 결과(`result.csv`)를 생성하는 협업 파이프라인을 구축한다.
- 핵심 요구사항:
 - 연구자 1: 전처리 + 모델링 + 저장 자동화(Docker 이미지)
 - 연구자 2: 연구자 1 이미지와 Jupyter를 `docker-compose` 로 연결해 추론 수행


2) Docker Hub URL

- `https://hub.docker.com/r/pixar12372/pre_and_modeling`
- 사용 태그: `pixar12372/pre_and_modeling:1.1`

3) 연구자 1 데이터 전처리/모델링 결과 요약

전처리 핵심 사항

- 중복 행 제거: 총 64건
- 타깃 컬럼 정수화:
 - 기존 Performance Index 컬럼의 결과값은 모두 정수인데 반해 자료형은 `float` 로 구성됨.
 - `int` 로 변환하여 타입 일관성 확보
- 범주형 이진 인코딩: Extracurricular Activities 의 No/Yes 를 0/1 로 변환
- 시각화 결과 컬럼 모두 고른 분포를 보여주었고, Performance Index 항목은 정규 분포 형태를 따른다고 판단하여 극단치 제거하지 않음.




모델링


- 모델: `LinearRegression (scikit-learn)`
- 데이터 분할: `train_test_split(test_size=0.2, random_state=42)`
- 평가 지표: `RMSE (root_mean_squared_error)`
- 관측 성능: `RMSE = 2.0375`

산출물

- 학습 모델: `model.pkl`
- 실행 스크립트: `researcher_1/notebooks/main.py`
- 의존성 파일: `researcher_1/requirements.txt`

4) 코드 아키텍처





동작 설명

- Python 버전: 도커의 `jupyter/scipy-notebook` 이미지가 3.11 태그까지 존재하는 것을 확인하여 3.11 버전으로 진행.

연구자 1(researcher_1) Dockerfile

- `modeling` 서비스(연구자 1)가 `main.py` 를 실행해 모델을 생성한다.
- 생성된 `model.pkl` , `mission15_test.csv` , `requirements.txt` , `main.py` 를 공유 볼륨 (`/shared`)으로 복사한다.

연구자 2(researcher_2) docker-compose.yml

- 공유 볼륨의 `requirements.txt` 를 설치하고 노트북 서버를 시작한다.
- `inference.ipynb` 에서 연구자 1의 `main.py` 에서 전처리 함수(`yn_to_int`)를 임포트하여 `/shared/mission15_test.csv` 를 전처리한다.
- 복사해 둔 `/shared/model.pkl` 를 로드하여 예측 후 `result.csv` 를 저장한다.

5) 트러블슈팅 요약

- 문제: `pickle.load` 시 `numpy._core` 또는 `_ARRAY_API` 에러 발생
- 원인: 모델 저장 환경과 추론 환경의 NumPy/과학패키지 버전 불일치
- 조치: 연구자 1 `requirements.txt` 를 공유하고 연구자 2가 동일 버전 설치 후 커널 재시작